三省

可验证的多智能体编排调度平台

三省

取唐代三省制之意：中书起草，门下审核，尚书执行

写的人不审，审的人不写

大模型 Agent 工具编排调度平台赛题 · 初赛方案讲解

汇报卷目

卷一
研究背景
谁来判定完成

卷二
总体设计
三省分权与技术路线

卷三
关键技术
编排调度核查自循环

卷四
实现与实验
真实界面与实测数据

卷五
创新与展望
创新不足与下一步

多智能体流水线里，“完成”由谁来判定

一　自评偏差

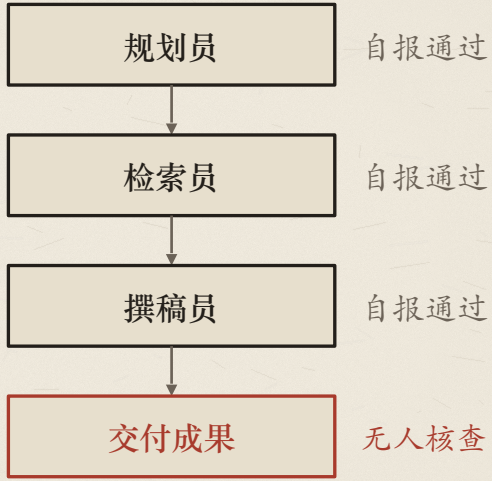
模型倾向于给自己的输出打高分，仅靠自我纠错难以发现错误〔1,2〕。

二　串行低效

检索、阅读、核查环环相扣，一份调研报告动辄十几分钟以上。

三　失败失控

出错后要么整体中断，要么带错继续；无界重试越改越差，成本失控。



图一　传统流水线：各环节自报通过

〔1〕Huang J, et al. Large Language Models Cannot Self-Correct Reasoning Yet. ICLR, 2024.　〔2〕Panickssery A, et al. LLM Evaluators Recognize and Favor Their Own Generations. NeurIPS, 2024.

按　研究问题——如何在**可控的时间与成本**内，交付**经独立核验**的结果

借三省制分权：起草、审核、执行各司其职



图二　系统内“三省的由来”说明（真实界面）

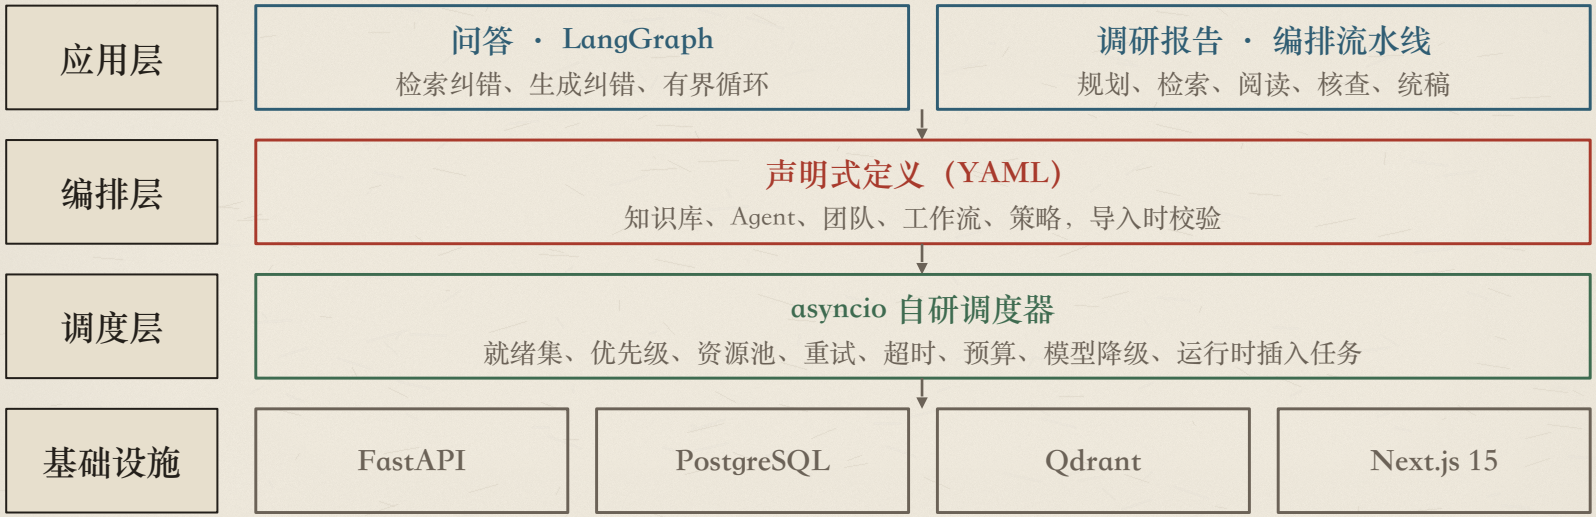
表一　三省与系统角色对应

三省	职掌	系统角色
中书省	起草	规划师、撰稿人、分析师
门下省	审核 · 封驳	独立核查员、质量门
尚书省	执行	调度器、检索员、修复员、主编

这是帮助理解分工的类比，而非对古代制度的复刻：门下省封驳整份诏令，核查员逐条说法地审。

按　核查员**看不到起草者的推理**，只凭证据判断；不达标即“封驳”退回重做

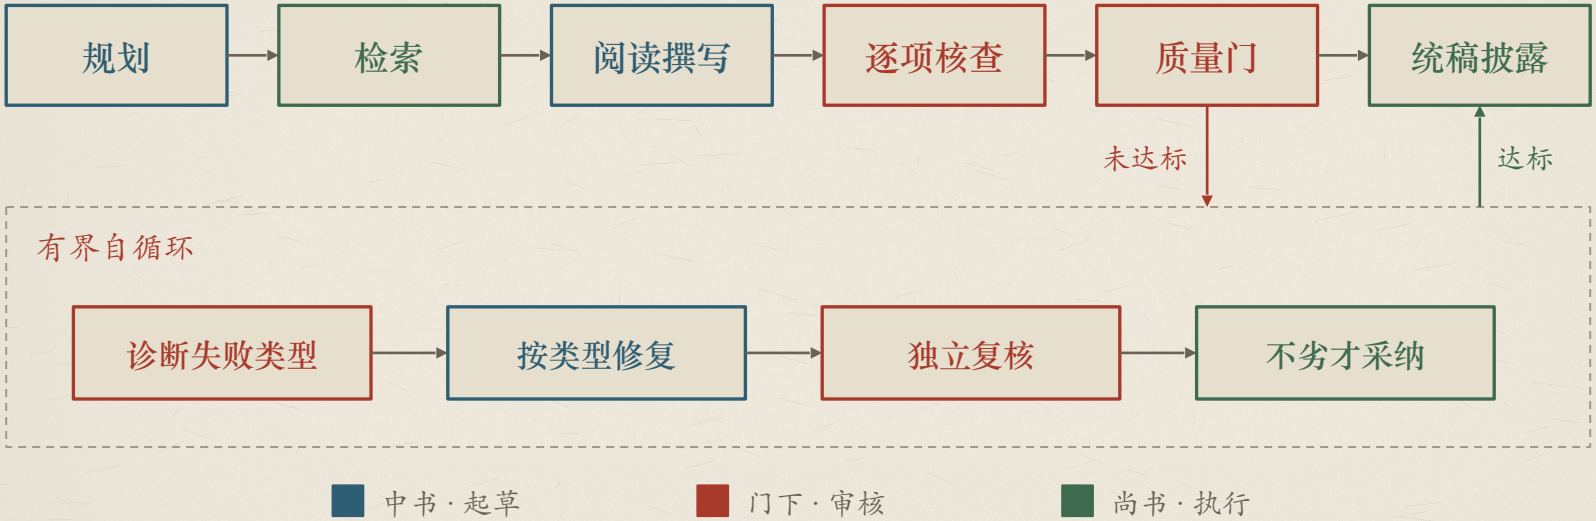
系统总体架构：一套编排引擎，支撑两个应用



图三　系统分层架构

按　两个应用共用一套编排引擎，运行全程可在编排页回放

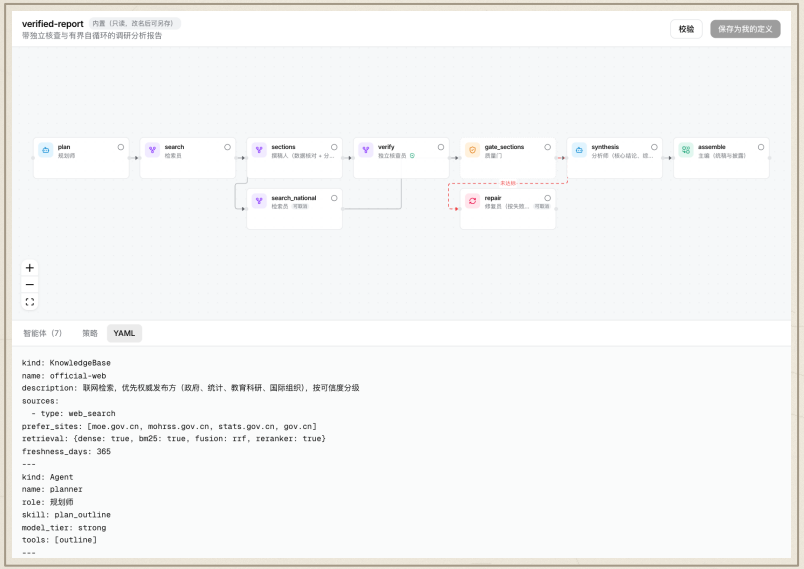
技术路线：起草—审核—修复—统稿的有界流程



图四　报告生成的技术路线

按　质量门未达标才进入修复，**修复结果不劣于原稿才采纳**

关键技术一：声明式编排——流程是可校验的数据



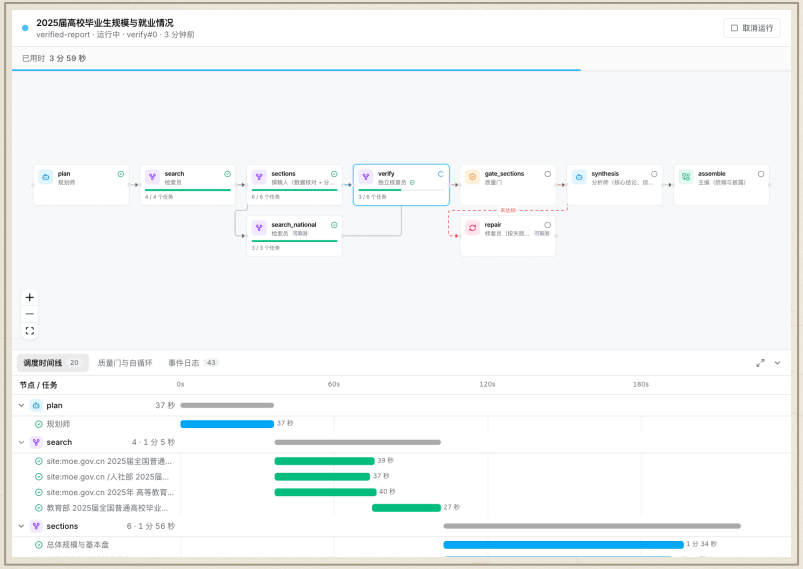
图五　工作流定义的画布与 YAML 视图（真实界面）

表二　五类声明对象

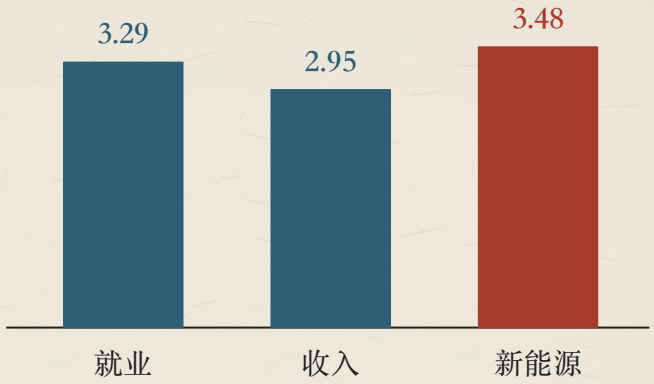
对象	声明内容
知识库	检索来源、优先站点、检索策略
Agent	角色、技能、模型档位与工具
团队	成员与主管
工作流	节点、依赖、按数据扇出、质量门
策略	并发、预算、修复轮次、模型

按　导入即校验：依赖成环、引用缺失、模型名非法，一律在运行前拒绝

关键技术二：动态调度与逐项流水线并行



图六　就业题运行中：画布与调度时间线实时更新



图七　三次真实运行的并行加速比（倍）

- 资源池分别限流：检索 3 路、模型 6 路；
- 下游逐项只等上游对应项，上游失败则对应项明确标为失败。

按　新能源题 545 秒内完成 27 个任务、430 次模型调用，并行加速比 3.48

关键技术三：独立核查——核查员看不到起草者的推理

表三　说法的四级判定

等级	判定依据
已核实	权威来源原文支持，或两个以上独立来源一致
单一来源	仅一个独立来源（转载计为同一来源）
有争议	有来源支持，另有可信来源说法不同
未能核实	没有资料明确支持

另有两条硬规则：说法被驳回两次才判为不成立；数据点须在来源原文中逐字找到。



图八　核查员节点

按　合成集误放行 0/46，真实网页误放行 0/15（改进前为 3/17）

关键技术四：有界自循环——只在确实变好时才采纳

算法一　有界自循环（在质量门内执行）

输入：草稿 D，最大轮次 R，预算 B

```
s ← 质量门(D)
for r ← 1 … R do
    if s 达标 或 已用预算 ⩾ 0.6B then break
    F ← 诊断失败类型(D)
    E ← 按类型修复(D, F)    ▷ 只改失败章节
    t ← 独立复核(E)
    if t 不劣于 s then D, s ← E, t
    else if 无进展 then break
return D, s
```



图九　新能源题质量门：首次 34%，修复后 51%

表四　三次真实运行的自循环

题目	首轮已核实	修复轮次	终稿已核实
就业	95%	0	95%
收入	72%	0	72%
新能源	34%	1	51%

按　新能源题五次改写中**四次被驳回、一次被采纳**；门槛为已核实说法占比不低于 50%

系统实现（一）：资料问答——结论可追溯到证据与来源



图十　回答附引用，逐条核对说法（真实界面）



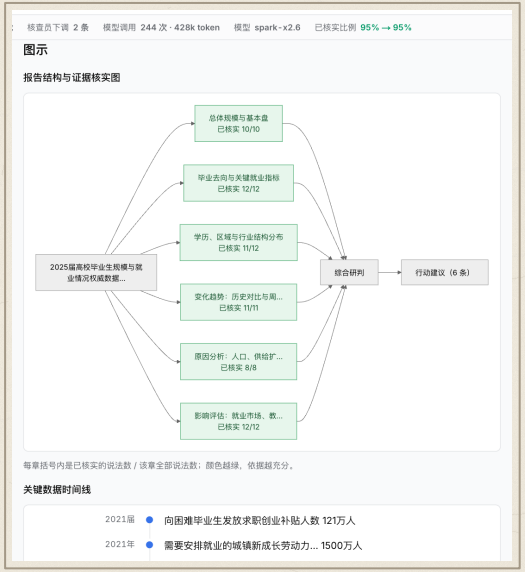
图十一　详细运作过程

按　完整方案在 13 个场景上召回@5 为 1.0，仅纠错的基线为 0.8

系统实现（二）：调研报告——逐条分级，图表由数据生成



图十二　报告首页：核实分级与核心结论



图十三　报告结构与证据核实图

按　每章标注已核实说法数；图表随正文导出 PDF 与 Word

实验结果：核查零误放行，三次真实运行加速 2.95 – 3.48 倍

表五　核查评测

数据集	样本	等级准确率	误放行	抽取召回
合成集	48 例 / 100 条说法	97.7%	0 / 46	88%
真实网页	28 例 / 60 条说法	100%（n=46）	0 / 15	76.7%

表六　三次真实运行

题目	耗时	任务	模型调用	token	并行加速比
2025 届高校毕业生就业	379 秒	23	244	427,689	3.29
2025 年居民人均可支配收入	436 秒	21	265	559,151	2.95
2025 年新能源汽车销量	545 秒	27	430	778,209	3.48

按　后端测试 487 项通过（4 项跳过），端到端界面用例 18 个；样本量有限，置信区间见方案书

创新点与不足

一　起草与审核分权

核查员看不到起草推理，只凭证据判断。

二　逐项流水线并行

读完一条核查一条，加速 2.95 – 3.48 倍。

三　有界自循环

先诊断再修复，不劣才采纳，三重停止条件。

四　声明式且可回放

YAML 定义、导入即校验，全程事件可回放。

表七　不足与改进方向

不足	改进方向
样本量有限，置信区间较宽	扩大真实网页评测集
仅接入单一模型	接入多模型并横向对比
无断点续跑	运行断点续跑
无拖拽式编排器	拖拽式流程搭建
反馈优化仅给建议	从建议走向自动调参

按　可信不靠事后检查，而是**平台的默认行为**

敬请批评指正

三省

三省　写的人不审，审的人不写